



Bloc 3 : Analyse prédictive de données structurées par l'intelligence artificielle

Optimiser l'offre et la demande par détection des hot-zones



[Dépôt Github](#)

Contexte et besoins du projet

- **Contexte**

- **Uber**, startup mondiale leader dans la mobilité, présente dans 70 pays et 900 villes, avec un CA de 14 milliards de dollars
- **Activités** : VTC, livraison de repas (Uber Eats), colis, fret, etc.
- **Mission** : Révolutionner les transports à l'échelle mondiale

- **Problème identifié**

- déséquilibre entre offre (conducteurs) et demande (utilisateurs)
- résultat : temps d'attente de 10–15 min -> seuil critique, car les utilisateurs annulent au-delà de 5–7 min

- **Besoin :**

- développer un système pour recommander aux conducteurs des "hot-zones" (zones à forte demande) en (pseudo-)temps réel

Objectifs et périmètre du projet

- **Objectif**

- créer un algorithme pour identifier les hot-zones en fonction des données de trajets
- développer un tableau de bord ou cartes pour visualiser les résultats de manière intuitive

- **Périmètre**

- Ville cible : New York (phase pilote)
- Données :
 - Utilisation exclusive des données Uber Trip Data pour NYC
 - sur année 2014 et 2015


Data exploration : phase 1

compréhension du dataset

cleaning, préparation


Analyse du trafic - par mois et année

Nombre de courses Uber par mois et année



- trafic en plein croissance
- pas de saisonnalité apparente
- des mois manquants
- difficulté d'exploiter les données de 2015
 - pas de coordonnées
 - coordonnées des bases non liées à la course


Analyse des jours et heure (data 2014)



- 4 534 327 pickups : dataset volumineux
- jeudi et vendredi les + chargés
- mardi au samedi : 3/4 des courses
- HP Matin : 6h-9h
- HP Soir : 16h-19h (voire 15h à 21h)

Analyse jours x heure par heatmap (data 2014)

Heatmap des pickups jour de semaine x heure



- week-end + lundi plus calmes
- essentiel concentré sur semaine, surtout jeudi et vendredi en HPS
- HPM et HPS marquées aux mêmes heures sur la semaine, sauf week-end pour laquelle l'HPM disparaît
- HP Matin : 6h-9h

Machine Learning : phase 2 modélisation non supervisée

Réduction du dataset pour un premier modèle de clustering


Pour réduire la taille des données tout en gardant une bonne représentativité

- on va garder
 - le mois de **septembre** (le plus chargé)
 - le **jeudi** qui est la journée type la plus chargée
 - sur l'**HPS de 16h à 19h** pour l'homogénéité (ou l'HPM de 6h à 9)


=> 44.194 courses

Choix du nombre de clusters : WCSS method + silhouette score

Silhouette score en fonction de k




Méthode du coude — WSS (inertia) en fonction de k



- Silhouette score chute fortement jusqu'à $k \approx 8-10$ (mais cluster trop larges)
 - puis chute encore vers $k=21$
 - WCSS ne diminue plus notablement au delà de $k=15$
- on choisira $k=21$ comme nombre de clusters

Premier modèle KMeans (jeudi sept 2014 HPS 16-19h)

Clusters K-Means (k=21) — jeudis de septembre, 16h–19h




- k = 21 clusters
- metric=manhattan
- 1000 iterations

mais...

- NYC trop compacte et concentrée
- lecture difficile
- difficulté sur le choix du nombre de clusters
- sensible aux outliers

Premier modèle KMeans (jeudi sept 2014 HPS 16-19h)

Centroïdes des clusters (taille = nombre de pickups)



- affichage des centroïdes avec leurs poids respectifs
- permet meilleure visu des hot-zones

mais...

- serait préférable d'ajouter polygones des hot-zones
- + la densité des courses/m²
- adaptation taille centroïdes / zoom

Amélioration du modèle : DBScan

DBSCAN — HPS soir jeudi septembre (eps=200m → 12 hot-zones)




- trouve de lui-même les clusters
- élimine les outliers automatiquement

mais...

- EPS_M=200m
- MIN_SAMPLES=50
- paramétrage très sensible pour obtenir un rendu correct

Amélioration du modèle : HDBScan


HDBSCAN — HPS soir jeudi septembre (leaf, min_cluster_size=50 → 48 hot-zones)



- EPS_M varie automatiquement donc trouve mieux les densités différentes
- méthode “leaf” : clusters
 - plus granulaires
 - moins stables
 - moins gros

Amélioration du modèle : H3 binning hexagonal

H3 résolution 8 — HPM matin jeudi septembre



- simple
- pas d'hyperparamètres!
(hormis la taille de l'hexagone)
- calcul de la densité immédiat
- visu plus précise des spots très denses

Généralisation

Par heure et par jour sur un dashboard Streamlit

<https://jedha-project-06-uber-e5a6exs9vw6pv6o6onweus.streamlit.app/>

Conclusions

Conclusions

- **K-Means pas très adapté dans ce cas**
- **Modèle H3**
 - **plus simple à mettre en oeuvre**
 - **plus efficace en terme de visualisation**

Jedha - Data Science Fullstack

Certification CDSD (Concepteur développeur en science des données)



Questions ?